



**UNIVERSIDAD
DEL PACÍFICO**

Caso: Comportamiento de estudiantes

Trabajo Final de Ingeniería de Datos

Integrantes:

Brayan Anderson Rua Pomahuacre

Kevin Paolo Julca Lucano

Nicole Rashel Pando Cabezas

Rosa Leticia Ortiz Palomino

Tania Lisset Chavez Alvitez

Lima, 22 de junio del 2026

ÍNDICE

1. INTRODUCCIÓN	1
1.1 Contexto	1
1.2. Procesos y actividades del caso de estudio	2
2. DICCIONARIO DE DATOS	3
3. GRÁFICOS REPRESENTATIVOS DE LAS ETAPAS DE ADQUISICIÓN DE LA INFORMACIÓN DE LA EMPRESA	6
4. REQUERIMIENTOS DE LA BASE DE DATOS	7
5. DESARROLLO DEL MODELO ENTIDAD-RELACIÓN (MER)	12
6. DESARROLLO DEL MODELO RELACIONAL	21
7. NORMALIZACIÓN DE LA BASE DE DATOS	22
8. IMPLEMENTACIÓN DEL ESQUEMA SQL Server	
9. CREACIÓN DE CONSULTAS SQL AVANZADAS	
10. CREACIÓN DE FUNCIONES Y PROCEDIMIENTOS BÁSICOS	
11. CREACIÓN DE REPORTES DE VISUALIZACIÓN DE PYTHON	
12. LECCIONES APRENDIDAS	

1. INTRODUCCIÓN

1.1. Contexto de la educación superior y toma de decisiones

La toma de decisiones basada en datos se ha convertido en un componente fundamental para la gestión eficiente de las instituciones de educación superior. En un contexto caracterizado por transformación digital, incremento de la matrícula, internacionalización y diversidad creciente de perfiles estudiantiles, las universidades requieren información precisa, actualizada y accesible para comprender las necesidades de sus estudiantes y diseñar estrategias adecuadas. No obstante, la disponibilidad de datos no garantiza por sí misma una gestión efectiva: cuando los registros académicos, administrativos, tecnológicos y de bienestar se encuentran dispersos, la institución pierde capacidad para convertirlos en conocimiento útil y oportuno (Broberg & Golden, 2023; OECD, 2023).

Esta dificultad ha sido reconocida por organismos internacionales. UNESCO advierte que la formulación de políticas de educación superior basadas en evidencia exige acceso sistemático a datos confiables, capacidades analíticas e infraestructura integrada; sin embargo, la información disponible sigue siendo fragmentada e inconsistente en numerosos países. De acuerdo con el debate reciente sobre brechas de datos en educación superior, los países reportan, en promedio, menos del 50% de las estadísticas de educación superior requeridas por el Instituto de Estadística de la UNESCO, con brechas regionales importantes que afectan la planificación y la comparación entre sistemas (Pedró et al., 2025; UNESCO, 2025a).

La problemática no se limita a países en desarrollo. Incluso en economías avanzadas, la OECD señala que la transformación digital de la educación superior requiere políticas capaces de coordinar recursos, regulación, gobernanza, capacidades humanas y sistemas interoperables. El uso estratégico de datos, plataformas digitales, sistemas de información estudiantil y herramientas de análisis permite monitorear indicadores relevantes, evaluar resultados y orientar decisiones institucionales con mayor precisión (Broberg & Golden, 2023; OECD, 2023).

Las consecuencias de una gestión con baja visibilidad son significativas. Desde la perspectiva institucional, la información incompleta puede generar ineficiencias en la asignación de recursos, dificultades para diseñar programas de apoyo, limitaciones en procesos de acreditación y menor capacidad para responder de forma proactiva ante problemas de rendimiento, permanencia o bienestar. La literatura sobre analítica educativa muestra que los datos institucionales pueden apoyar la identificación temprana de estudiantes en riesgo, la entrega de retroalimentación y la planificación de intervenciones, siempre que se integren con procesos humanos de acompañamiento (Dai et al., 2025; Jayaprakash et al., 2014; Wong & Li, 2020).

Para los estudiantes, la falta de mecanismos de seguimiento puede traducirse en una atención tardía de problemas académicos, económicos, tecnológicos o personales que afectan su trayectoria educativa. La deserción universitaria no suele ser un evento aislado, sino el resultado de una interacción progresiva entre desempeño académico, integración institucional, condiciones socioeconómicas, motivación, bienestar y factores externos. Por ello, anticipar señales de riesgo permite que las universidades intervengan antes de que el abandono se consolide (Bean, 1980; Behr et al., 2020; Tinto, 1975).

1.2. EduData Analytics

1.2.1. Descripción de la empresa

EduData Analytics es una empresa especializada en análisis e inteligencia de información para universidades alrededor del mundo. Su actividad principal consiste en

ayudar a instituciones de educación superior que generan grandes volúmenes de datos académicos, administrativos, tecnológicos y estudiantiles, pero que muchas veces enfrentan dificultades para convertir esa información en conocimiento útil para comprender lo que ocurre dentro de su comunidad universitaria.

La empresa parte de una necesidad concreta: una universidad puede tener miles de registros sobre rendimiento académico, asistencia, participación en plataformas virtuales, acceso a recursos, uso de servicios, bienestar estudiantil y permanencia; sin embargo, cuando esos datos se encuentran dispersos o no se analizan de manera estructurada, resulta difícil identificar problemas prioritarios, reconocer grupos que requieren mayor atención y decidir dónde intervenir primero.

Frente a esta necesidad, EduData Analytics ofrece un sistema especializado para recopilar, organizar, procesar, analizar y visualizar información universitaria. A través de reportes, indicadores, dashboards y vistas dinámicas, la empresa permite que cada universidad observe con mayor claridad su realidad institucional, detecte patrones, encuentre brechas y descubra oportunidades de mejora. Esta propuesta se alinea con el avance de los sistemas de información estudiantil, la interoperabilidad y el uso de datos para mejorar la calidad, la equidad y la eficiencia de la gestión educativa (OECD, 2023; UNESCO IESALC, 2026).

La propuesta de valor de EduData Analytics busca que los datos dejen de ser únicamente registros acumulados y se conviertan en una herramienta estratégica para la gestión universitaria. Detrás de cada dato existe una historia académica, una necesidad institucional y una oportunidad para tomar mejores decisiones. Por ello, la empresa acompaña a sus clientes en la transformación de información dispersa en evidencia valiosa para mejorar la experiencia estudiantil, fortalecer la permanencia y orientar acciones más precisas dentro de la universidad.

1.2.2. Historia de la empresa

La historia de EduData Analytics comenzó hace cinco años, cuando sus fundadores identificaron una necesidad cada vez más evidente en el sector universitario: muchas instituciones de educación superior generaban grandes volúmenes de información, pero no siempre contaban con una forma clara de interpretarla y convertirla en conocimiento útil para su gestión. A partir de esa realidad, se creó una empresa orientada a ayudar a las universidades a descubrir el valor que ya existía dentro de sus propios datos.

En los primeros proyectos, la empresa trabajó con universidades que buscaban comprender con mayor precisión lo que ocurría dentro de su comunidad académica. Algunas instituciones necesitaban analizar el rendimiento de sus estudiantes; otras buscaban monitorear la participación en plataformas virtuales, evaluar la permanencia estudiantil, identificar riesgos de deserción o reconocer brechas en el acceso a recursos institucionales. Estas experiencias mostraron que cada universidad posee una realidad distinta y que, por ello, la información debe analizarse considerando su propio contexto.

Con el tiempo, la propuesta se consolidó alrededor de un sistema capaz de organizar, procesar y visualizar información universitaria mediante reportes, indicadores, dashboards y vistas analíticas. El desarrollo no respondió únicamente a una necesidad tecnológica, sino también a la comprensión de los desafíos reales que enfrentan las universidades al interpretar grandes cantidades de datos y convertirlas en decisiones concretas.

El alcance de la empresa se extendió hacia universidades de distintos países. En esos contextos, EduData Analytics encontró realidades académicas diversas, pero también un desafío común: transformar grandes volúmenes de datos en información realmente útil para la gestión universitaria. Esta experiencia internacional permitió fortalecer el sistema, adaptarlo a diferentes modelos educativos, estructuras institucionales y necesidades de análisis, consolidando una visión global sobre el valor de los datos en la educación superior.

1.2.3. Evolución hacia modelos predictivos

En los últimos meses, la trayectoria de EduData Analytics permitió identificar una nueva oportunidad dentro de la información histórica construida junto con las universidades. Después de varios años recopilando, organizando y analizando datos académicos y estudiantiles, la empresa cuenta con una base más sólida para desarrollar modelos que permitan ir más allá del análisis descriptivo.

Como parte de esta nueva etapa, hace tres meses se inició el entrenamiento del primer modelo predictivo de la empresa, orientado a estimar el riesgo de deserción estudiantil. Para ello, se incorporó información histórica sobre la trayectoria de los estudiantes, incluyendo variables académicas, participación, acceso a recursos, uso de plataformas, indicadores de bienestar y el registro de si el estudiante desertó o continuó en la institución. La evidencia disponible muestra que los registros tempranos de trayectoria académica y comportamiento pueden aportar señales relevantes para predecir abandono, siempre que se utilicen con criterios de interpretación, calidad de datos y acompañamiento institucional (Aulck et al., 2016; Baneres et al., 2020).

Esta nueva funcionalidad representa un paso importante en la evolución de la propuesta. Los reportes, indicadores y dashboards seguirán siendo la base del sistema; sin embargo, ahora se complementan con modelos predictivos que transforman la información histórica en una visión anticipada de los problemas universitarios. De esta manera, la empresa pasa de describir lo que ocurrió a apoyar la identificación de lo que podría ocurrir si no se interviene oportunamente.

1.2.4. Primera iniciativa predictiva: deserción estudiantil

Como respuesta a esta oportunidad, EduData Analytics decidió ampliar su propuesta de valor incorporando capacidades de analítica predictiva. Para ello, solicitó a sus clientes información histórica adicional que permitiera construir variables objetivo asociadas a distintos problemas identificados dentro de las instituciones educativas. Entre los desafíos reportados por las universidades, uno de los más recurrentes, costosos y estratégicamente relevantes fue la deserción estudiantil.

La relevancia de este fenómeno se sostiene en la literatura internacional. La deserción universitaria afecta a estudiantes, familias, instituciones y sistemas educativos porque implica pérdida de inversión, interrupción del proyecto profesional, reducción de oportunidades futuras y disminución de eficiencia institucional. Además, diversos estudios coinciden en que el abandono se explica por una combinación de factores académicos, económicos, personales, sociales e institucionales, por lo que requiere una lectura integral y no únicamente administrativa (Behr et al., 2020; Tinto, 1975).

En este contexto, la primera iniciativa predictiva de EduData Analytics consiste en estimar la probabilidad de deserción estudiantil mediante aprendizaje supervisado, específicamente a través de regresión logística. Esta metodología fue seleccionada por su interpretabilidad, facilidad de implementación, capacidad para estimar probabilidades y utilidad para explicar la relación entre variables de riesgo y resultado esperado. En proyectos institucionales, la interpretabilidad es especialmente importante porque las alertas deben ser comprensibles para tutores, coordinadores, áreas de bienestar y autoridades universitarias (Hosmer et al., 2013; Karimi-Haghighi et al., 2021).

La incorporación de esta funcionalidad permitirá aprovechar la información recopilada durante años para identificar patrones asociados al riesgo de abandono académico y generar alertas tempranas que faciliten intervenciones oportunas. Sin embargo, la alerta no debe entenderse como una sentencia automática sobre el estudiante, sino como una señal de priorización que debe ser revisada por equipos humanos. Las recomendaciones derivadas del modelo deben orientar acciones de acompañamiento académico, bienestar, apoyo financiero, tutoría o acceso tecnológico según el perfil integral del estudiante (Dai et al., 2025; Wong & Li, 2020).

De esta manera, EduData Analytics evoluciona desde una organización enfocada principalmente en análisis descriptivo hacia una empresa capaz de combinar ingeniería de datos, inteligencia de negocios y analítica predictiva. La nueva capacidad permitirá a las universidades identificar estudiantes con mayor riesgo de deserción, optimizar la asignación de recursos institucionales, diseñar estrategias de apoyo más personalizadas y fortalecer las acciones orientadas a mejorar la permanencia estudiantil.

2. Diccionario de datos

2.1 AcademicPeriod

Atributo	Descripción	TIPO DE DATO	Valores admitidos
Academic_Period_id	Identificador único del periodo académico.	int	>=1
start_date	Fecha de inicio del periodo académico.	date	Rango registrado: 2025-03-01 - 2025-08-01
Period_year	Año del periodo académico.	int	2025
period_term	Ciclo académico dentro del año.	int	1, 2.
end_date	Fecha de cierre del periodo académico.	date	Rango registrado: 2025-07-31- 2025-12-31.

2.2 AdultStudent

Atributo	Descripción	TIPO DE DATO	Valores admitidos
adult_student_id	Identificador único del estudiante adulto.	int	>=1
financial_autonomy	Indica si el estudiante tiene autonomía financiera.	varchar(3)	Yes, No.
is_employed	Indica si el estudiante trabaja.	varchar(3)	Yes, No.

student_id	Fk - viene de la tabla Student	int	>=1
------------	--------------------------------	-----	-----

2.3 Country

Atributo	Descripción	TIPO DE DATO	Valores admitidos
country_id	Identificador único del país.	int	1 - 50.
development_id	Fk de tabla developmentLevel	int	Todos los valores del campo referenciado y puede ser null
country_name	Nombre del país.	varchar(100)	Argentina, Australia, Bangladesh, Bolivia, Brazil, Cambodia, Canada, Chile, China, Denmark, Ethiopia, France, Germany, Ghana, India, Indonesia, Japan, Kazakhstan, Kenya, Kuwait, Laos, Malaysia, Mexico, Morocco, Nepal, Netherlands, New Zealand, Nigeria, Norway, Oman, Pakistan, Peru, Philippines, Poland, Qatar, Romania, Saudi Arabia, Singapore, South Africa, South Korea, Sri Lanka, Sweden, Switzerland, Tanzania, Thailand, Turkey, UAE, UK, USA, Vietnam.

2.4 CountryIndicator

Atributo	Descripción	TIPO DE DATO	Valores admitidos
Country_Indicator_id	Identificador único del indicador de país.	int	1 - 50.
indicator_year	Año del indicador.	int	2025
poverty_rate_percent	Porcentaje de pobreza del país.	decimal(5,2)	0 - 100.
internet_infrastructure_index	Índice de infraestructura de internet.	decimal(5,2)	0 - 100.
average_internet_speed_mbs	Velocidad promedio de internet en Mbps.	decimal(8,2)	>= 0.
country_id	FK - tabla Country	int	Todos los valores del campo referenciado y puede ser null

2.5 DevelopmentLevel

Atributo	Descripción	TIPO DE DATO	Valores admitidos
Development_Level_id	Identificador único del nivel de desarrollo.	int	[1-3]
Development_level_name	Nombre del nivel de desarrollo.	varchar(50)	Developed, Underdeveloped.

2.6 DeviceType

Atributo	Descripción	TIPO DE DATO	Valores admitidos
Device_type_id	Identificador único del tipo de dispositivo.	int	>=1.
Device_name	Nombre del dispositivo utilizado.	varchar(50)	Smartphone, Laptop, PC.

2.7 Employee

Atributo	Descripción	TIPO DE DATO	Valores admitidos
employee_id	Identificador único del empleado.	int	>=1
First_name	Nombre del empleado.	varchar(80)	Camila, Mateo, Sofia, ..
LastName	Apellido del empleado.	varchar(80)	Ramirez, Torres, Villanueva, ..
hire_date	Fecha de contratación.	date	>=2024-01-15
job_role	Cargo del empleado.	varchar(80)	Academic Coordinator, Data Analyst, System Administrator.
user_id	FK - tabla usuario	int	Todos los valores del campo referenciado y puede ser null

2.8 FieldOfStudy

Atributo	Descripción	TIPO DE DATO	Valores admitidos
field_of_study_id	Identificador único del campo de estudio.	int	>=1.
field_of_study	Nombre del campo de estudio.	varchar(80)	Arts, Business, Law, Medicine, STEM, Social Sciences.

2.9 MetricDefinition

Atributo	Descripción	TIPO DE DATO	Valores admitidos
Metric_id	Identificador único de la métrica.	int	1 - 32.
metric_name	Nombre de la métrica.	varchar(100)	academic_motivation, ads_clicked_per_week, ads_viewed_per_day, adult_content_exposure, anxiety_score, attention_span_minutes, average_session_length_minutes, brain_rot_level, class_attendance_rate, comments_written_per_day, cyberbullying_exposure, depression_score, digital_addiction_score, digital_spending_per_month, education_content_hours, entertainment_content_hours, family_income_level, impulse_purchase_scale

			e, internet_access_hours, late_night_usage, likes_given_per_day, news_content_hours, perceived_financial_impact, posts_created_per_week, productivity_score, sessions_per_day, short_video_hours, sleep_hours, social_media_hours, stress_level, study_hours_per_week, wellbeing_percent.
category	Categoría de la métrica.	varchar(80)	academic, advertising, content, digital_access, digital_behavior, health, interaction, risk, socioeconomic, spending, wellbeing.
unit	Unidad de medida de la métrica.	varchar(50)	coded_boolean, coded_category, count_per_day, count_per_week, hours_per_day, hours_per_night, hours_per_week, minutes, money_per_month, percent, score_0_10, score_0_100, score_1_10, null.

2.10 Mide

Atributo	Descripción	TIPO DE DATO	Valores admitidos
metric_id	Métrica registrada en la evaluación.	int	[1 - 32]

Assessment_id	Evaluación donde se registró la métrica.	bigint	>=1
metric_value	Valor numérico de la métrica.	decimal(12,2)	0 - 500.

2.11 MinorStudent

Atributo	Descripción	TIPO DE DATO	Valores admitidos
minor_student_id	Identificador único del estudiante menor de edad.	int	>=1
guardian_type	Tipo de apoderado.	varchar(30)	Father, Mother, Guardian.
guardian_consent	Consentimiento del apoderado.	varchar(3)	Yes, No.
student_id	FK - tabla student	int	Todos los valores del campo referenciado y puede ser null

2.12 Nationality

Atributo	Descripción	TIPO DE DATO	Valores admitidos
nationality_id	Identificador único de la nacionalidad.	int	[1 - 50]
nationality_name	Nombre de la nacionalidad.	varchar(100)	American, Argentinian, Australian, Bangladeshi, Bolivian, Brazilian, British, Cambodian, Canadian, Chilean, Chinese, Danish, Dutch, Emirati, Ethiopian, Filipino, French, German, Ghanaian, Indian, Indonesian, Japanese, Kazakh, Kenyan, Kuwaiti, Lao, Malaysian, Mexican, Moroccan, Nepalese, New Zealander, Nigerian,

			Norwegian, Omani, Pakistani, Peruvian, Polish, Qatari, Romanian, Saudi, Singaporean, South African, South Korean, Sri Lankan, Swedish, Swiss, Tanzanian, Thai, Turkish, Vietnamese.
--	--	--	---

2.13 Student

Atributo	Descripción	TIPO DE DATO	Valores admitidos
student_id	Identificador único del estudiante.	int	>=1
gender	Género del estudiante.	varchar(20)	Female, Male, Other.
country_id	País asociado al estudiante.	int	Todos los valores del campo referenciado y puede ser null
usuario_id	FK- tabla Users	int	Todos los valores del campo referenciado y puede ser null

2.14 StudentAssessment

Atributo	Descripción	TIPO DE DATO	Valores admitidos
Assessment_id	Identificador único de la encuesta o evaluación.	int	>=1
survey_number	Número de encuesta aplicada.	tinyint	[1 - 6]
urban_rural	Zona urbana o rural.	varchar(20)	Urban, Rural.
education_level	Nivel educativo.	varchar(30)	Undergraduate, Postgraduate.

sent_date	Fecha de envío.	date	2025-03-08 - 2025-12-08.
reception_date	Fecha de recepción.	date	2025-03-08 - 2025-12-18
parents_divorced	Indica si los padres están divorciados.	varchar(3)	Yes, No.
age	Edad del estudiante.	tinyint	16 - 25.
Device_type_id	Tipo de dispositivo usado.	int	Todos los valores del campo referenciado y puede ser null
academic_period_id	Periodo académico de la encuesta.	int	Todos los valores del campo referenciado y puede ser null
field_of_study_id	Carrera asociada a la encuesta.	int	Todos los valores del campo referenciado y puede ser null
student_id	Estudiante evaluado.	int	Todos los valores del campo referenciado y puede ser null

2.15 Student_nationality

Atributo	Descripción	TIPO DE DATO	Valores admitidos
nationality_id	Nacionalidad asociada al estudiante.	int	1 - 50.
student_id	Estudiante asociado a la nacionalidad.	int	Todos los valores del campo referenciado y puede ser null

2.16 University

Atributo	Descripción	TIPO DE DATO	Valores admitidos
university_id	Identificador único de la universidad.	int	>=1.
university_name	Nombre de la universidad.	varchar(200)	Ejemplos: Buenos Aires Institute of Technology, Highland Argentina International College, Northbridge University of Buenos Aires, Riverstone Argentina Metropolitan University, Highland Australia International College, Northbridge University of Sydney, Riverstone Australia Metropolitan University, Sydney Institute of Technology.
country_id	País de la universidad.	int	1 - 50 y puede ser null


2.17 User

Atributo	Descripción	TIPO DE DATO	Valores admitidos
user_id	Identificador único del usuario.	int	>=100001 - 900003.
email	Correo electrónico del usuario.	varchar(150)	Ejemplos: student00001_tanzania@ student.synthetic.edu, student00002_turkey@st udent.synthetic.edu, student00003_germany@ student.synthetic.edu, student00004_qatar@stu dent.synthetic.edu,

user_name	Nombre de usuario.	varchar(100)	15003 valores registrados. Ejemplos: student00001_tanzania, student00002_turkey, student00003_germany, student00004_qatar, student00005_morocco, student00006_south.africa, student00007_qatar, student00008_switzerland.
password	Contraseña del usuario.	varchar(255)	Ejemplos: Pwd00001!2025, Pwd00002!2025, Pwd00003!2025,
created_at	Fecha y hora de creación del usuario.	date	2025-02-15 - 2025-02-15.
user_role	Rol del usuario.	varchar(30)	estudiante, administrador.

3. GRÁFICOS REPRESENTATIVOS DE LAS ETAPAS DE ADQUISICIÓN DE LA INFORMACIÓN DE LA EMPRESA

Fig. 1 BPMN Proceso de adquisición de información



Fuente: Elaboración propia

El proceso modelado en el sistema MindTech, desarrollado por EduData, describe el flujo integral de recolección, procesamiento y análisis de datos para generar reportes que

apoyen la toma de decisiones en instituciones académicas. Inicia con el equipo de investigación de la ONG, encargado de diseñar y distribuir encuestas dirigidas a recopilar información sobre el bienestar digital, cognitivo y socioeconómico de los estudiantes. Una vez obtenidas las respuestas, los datos son consolidados y enviados a la plataforma MindTech, donde el equipo técnico realiza su integración, validación, ordenamiento y corrección, con el fin de garantizar la calidad, consistencia e integridad de la información antes de almacenarla en una base de datos estructurada. Posteriormente, el sistema procesa estos datos para generar reportes analíticos detallados, los cuales son enviados a las universidades, permitiéndoles analizar los resultados obtenidos e identificar oportunidades de mejora relacionadas con el bienestar y desempeño estudiantil. De esta manera, el proceso culmina transformando datos recopilados en información valiosa que facilita la comprensión de las necesidades de los estudiantes y contribuye a la toma de decisiones institucionales basadas en evidencia.

4. Requerimientos

El alcance de esta primera etapa llega hasta el diseño conceptual y funcional de la base de datos que soportará el análisis descriptivo y la primera iniciativa predictiva de deserción estudiantil. No se implementan todavía el modelo entidad-relación, el modelo relacional, la normalización formal, el esquema SQL Server ni las consultas avanzadas; estas partes corresponden a etapas posteriores del trabajo.

La base de datos se orienta a tres objetivos principales: integrar información dispersa de universidades, generar indicadores útiles para dashboards y almacenar datos históricos que permitan entrenar y ejecutar un modelo de regresión logística para estimar riesgo de deserción. El sistema no reemplaza el juicio humano ni decide sanciones académicas; su finalidad es apoyar la priorización de acompañamiento y la toma de decisiones informada.

4.1. Requerimientos funcionales

Código	Requerimiento	Descripción
RF-01	Registrar universidades cliente	La base de datos debe almacenar universidades de distintos países, su tipo de gestión y su relación con el país correspondiente.
RF-02	Registrar estudiantes	El sistema debe almacenar estudiantes de forma pseudonimizada, evitando datos personales innecesarios para el análisis.
RF-03	Gestionar periodos académicos	Debe permitir registrar periodos por año, ciclo, fecha de inicio y fecha de cierre para analizar la evolución temporal.
RF-04	Almacenar evaluaciones por estudiante	Debe registrar evaluaciones periódicas con variables académicas, digitales, económicas y de bienestar.
RF-05	Conservar variable objetivo	Debe guardar el estado de deserción o continuidad del estudiante como variable objetivo para entrenamiento y validación del modelo.
RF-06	Normalizar métricas	Debe permitir almacenar métricas en una tabla de definición y otra de valores para evitar columnas repetidas y facilitar nuevas métricas.
RF-07	Registrar ejecuciones del modelo	Debe almacenar versión del modelo, fecha de ejecución, umbral utilizado y parámetros mínimos necesarios para trazabilidad.

RF-08	Guardar predicciones	Debe registrar probabilidad de deserción, nivel de riesgo y periodo asociado a cada estudiante evaluado.
RF-09	Asignar recomendaciones	Debe permitir vincular una predicción con recomendaciones o intervenciones sugeridas, sin reemplazar la decisión humana.
RF-10	Generar consultas analíticas	Debe facilitar consultas por universidad, país, periodo, carrera, cohorte, nivel de riesgo y categoría de métrica.
RF-11	Mantener historial	Los datos históricos no deben sobrescribirse; toda actualización relevante debe conservar periodo, fecha y origen.
RF-12	Soportar reportes y dashboards	El modelo debe entregar información agregada y filtrable para tableros de control institucional.

4.2. Requerimientos no funcionales

Código	Requerimiento	Descripción
RNF-01	Integridad referencial	Todas las claves foráneas deben mantener consistencia entre estudiantes, universidades, países, periodos, evaluaciones, métricas y predicciones.
RNF-02	Normalización	La base debe diseñarse al menos hasta tercera forma normal para reducir redundancia, anomalías de actualización y dependencias indebidas.
RNF-03	Seguridad y confidencialidad	La información sensible debe tratarse con pseudonimización, control de roles y acceso mínimo necesario.
RNF-04	Escalabilidad multipaís	El diseño debe permitir incorporar universidades de distintos países sin modificar la estructura principal.
RNF-05	Calidad de datos	El sistema debe validar rangos, valores permitidos, campos obligatorios, duplicados y consistencia temporal.
RNF-06	Trazabilidad	Cada carga, evaluación, predicción e intervención debe ser rastreable por fecha, periodo y entidad responsable.
RNF-07	Rendimiento	Las consultas frecuentes deben ejecutarse eficientemente mediante índices en claves primarias, foráneas y campos de filtro.
RNF-08	Interoperabilidad	El modelo debe admitir integración con sistemas académicos, LMS y herramientas de visualización mediante exportaciones o APIs.
RNF-09	Transparencia analítica	Las predicciones deben acompañarse de variables explicativas o criterios de interpretación para facilitar decisiones responsables.
RNF-10	Auditabilidad	Debe existir capacidad de revisar qué modelo, datos y umbrales produjeron cada alerta.

4.3. Reglas de negocio

Código	Regla de negocio
RB-01	Cada universidad pertenece a un solo país, pero un país puede tener muchas universidades.
RB-02	Cada estudiante pertenece a una sola universidad dentro del sistema integrado de EduData Analytics.


RB-03	Un estudiante puede tener muchas evaluaciones, pero no debe existir más de una evaluación con el mismo estudiante, periodo y número de encuesta.
RB-04	El estado de deserción solo debe confirmarse cuando el periodo académico haya cerrado o cuando la universidad reporte retiro definitivo.
RB-05	Solo estudiantes activos deben ser enviados al proceso de predicción operativa; los desertores históricos se usan para entrenamiento y validación.
RB-06	La probabilidad de deserción debe clasificarse en riesgo bajo, medio o alto según umbrales definidos y documentados por versión del modelo.
RB-07	Las recomendaciones no deben ejecutarse de forma automática; deben ser revisadas por el área responsable de la universidad.
RB-08	Los indicadores sensibles deben presentarse de forma agregada en dashboards, salvo usuarios autorizados para seguimiento individual.
RB-09	Toda intervención asignada debe registrar estado para evaluar si fue atendida y si contribuyó a la permanencia del estudiante.
RB-10	Las métricas nuevas deben registrarse en MetricDefinition antes de almacenar valores en StudentMetricValue.

4.4. Alcance de la primera iniciativa predictiva


La primera iniciativa predictiva se limita a estimar la probabilidad de deserción estudiantil a partir de datos históricos disponibles y variables asociadas a la trayectoria académica, participación digital, acceso tecnológico, condición económica y bienestar. Para fines del diseño de base de datos, el modelo no se implementa todavía en SQL Server, pero sí se preparan las entidades necesarias para almacenar datos de entrenamiento, versiones del modelo, ejecuciones, predicciones y recomendaciones.

El resultado principal del modelo será una probabilidad entre 0 y 1, acompañada de un nivel de riesgo y de una recomendación de intervención. Esta información debe ser usada como apoyo para la gestión universitaria y no como decisión automática. Por ello, el diseño debe conservar trazabilidad de datos, versión del modelo y estado de atención de cada recomendación.

5. MER



6. MR



Dado que la relación Mide del MER tiene cardinalidad M:N, esta se vuelve una tabla en el MR

7. Normalización

Primera Forma Normal (1FN)

Nationality_name era un atributo multivaluado, por lo que violaría el principio de atomicidad y generaría repetición en el campo.

¿Cómo se soluciona?

Descomponer el atributo multivaluado Nacionalidad para garantizar que cada celda de la tabla contenga un único valor atómico:


- Separación en entidades:

Se creó una tabla Nationality donde cada nacionalidad vive como un registro único (con su propio nationality_id). Esto elimina la repetición de nombres de países en la tabla principal.

- Creamos una tabla intermedia (Relacion N:M): .

Un estudiante puede tener más de una nacionalidad (o una nacionalidad puede pertenecer a muchos estudiantes), por la relación N:M creamos la tabla intermedia Student_nacionalidad

Resultado:



Segunda Forma Normal (2FN)

El modelo cumple con la Segunda Forma Normal (2FN) porque previamente satisface la Primera Forma Normal y todos los atributos no clave dependen completamente de la clave primaria.

Tercera Forma Normal (3FN)

El modelo cumple con la Tercera Forma Normal (3FN) porque no presenta dependencias transitivas entre atributos no clave. Los datos descriptivos fueron separados en entidades independientes y relacionados mediante claves foráneas.

8. Implementación del esquema SQL Server

```

CREATE DATABASE StudentDigitalBehaviorDB;
GO

USE StudentDigitalBehaviorDB;
GO

CREATE TABLE DevelopmentLevel (
    Development_Level_id INT IDENTITY(1,1) NOT NULL,
    Development_level_name VARCHAR(50) NOT NULL,

    CONSTRAINT PK_DevelopmentLevel PRIMARY KEY
    (Development_Level_id),
    CONSTRAINT UQ_DevelopmentLevel_name UNIQUE
    (Development_level_name)
  )
  
```

```

);
GO

CREATE TABLE Country (
    country_id INT IDENTITY(1,1) NOT NULL,
    country_name VARCHAR(100) NOT NULL,
    development_id INT NOT NULL,

    CONSTRAINT PK_Country PRIMARY KEY (country_id),
    CONSTRAINT UQ_Country_name UNIQUE (country_name),
    CONSTRAINT FK_Country_DevelopmentLevel
        FOREIGN KEY (development_id)
        REFERENCES DevelopmentLevel (Development_Level_id)
);
GO

CREATE TABLE CountryIndicator (
    Country_Indicator_id INT IDENTITY(1,1) NOT NULL,
    indicator_year SMALLINT NOT NULL,
    poverty_rate_percent DECIMAL(5,2) NOT NULL,
    internet_infrastructure_index DECIMAL(5,2) NOT NULL,
    average_internet_speed_mbs DECIMAL(8,2) NOT NULL,
    country_id INT NOT NULL,

    CONSTRAINT PK_CountryIndicator PRIMARY KEY
(Country_Indicator_id),
    CONSTRAINT FK_CountryIndicator_Country
        FOREIGN KEY (country_id)
        REFERENCES Country (country_id),
    CONSTRAINT UQ_CountryIndicator_country_year UNIQUE (country_id,
indicator_year),
    CONSTRAINT CK_CountryIndicator_poverty CHECK
(poverty_rate_percent BETWEEN 0 AND 100),
    CONSTRAINT CK_CountryIndicator_infra CHECK
(internet_infrastructure_index BETWEEN 0 AND 100),
    CONSTRAINT CK_CountryIndicator_speed CHECK
(average_internet_speed_mbs >= 0)
);

```

```
GO
```

```
CREATE TABLE University (  
    university_id INT IDENTITY(1,1) NOT NULL,  
    university_name VARCHAR(200) NOT NULL,  
    university_type VARCHAR(80) NULL,  
    country_id INT NOT NULL,  
  
    CONSTRAINT PK_University PRIMARY KEY (university_id),  
    CONSTRAINT FK_University_Country  
        FOREIGN KEY (country_id)  
        REFERENCES Country (country_id),  
    CONSTRAINT UQ_University_country_name UNIQUE (country_id,  
university_name)  
);  
GO
```


9. Creación de consultas SQL avanzadas

- M1:

1. ¿Qué carreras presentan un nivel de productividad estudiantil promedio inferior a la media general de su propia universidad, segmentados por país e institución?

Pais	Universidad	Carrera	Total_Estudiantes_Evaluados	Productividad_Promedio_Carrera
Argentina	Buenos Aires Institute of Technology	Law	8	7.000000
Argentina	Buenos Aires Institute of Technology	STEM	11	8.000000
Argentina	Highland Argentina International College	Business	14	9.000000
Argentina	Highland Argentina International College	Medicine	17	8.000000
Argentina	Highland Argentina International College	STEM	14	9.000000
Argentina	Northbridge University of Buenos Aires	Business	12	8.000000
Argentina	Northbridge University of Buenos Aires	Law	13	9.000000
Argentina	Northbridge University of Buenos Aires	Social Sciences	12	9.000000
Argentina	Northbridge University of Buenos Aires	STEM	11	9.000000
Argentina	Riverstone Argentina Metropolitan University	Arts	10	8.000000
Argentina	Riverstone Argentina Metropolitan University	Business	10	8.000000
Australia	Highland Australia International College	Business	15	8.000000
Australia	Highland Australia International College	Social Sciences	14	8.000000
Australia	Highland Australia International College	STEM	15	9.000000

532 filas

2. ¿Qué estudiantes menores de edad no cuentan con el consentimiento del tutor, en qué universidad y país están, a qué tipo de tutor hay que solicitarlo y a qué email contactar?

Pais	Universidad	Estudiante_id	Tipo_Tutor	Email_Contacto
Brazil	Northbridge University of Sao Paulo	4899	Father	student04899_brazil@student.synthetic.edu
Cambodia	Riverstone Cambodia Metropolitan University	1558	Mother	student01558_cambodia@student.synthetic.edu
China	Highland China International College	12882	Father	student12882_china@student.synthetic.edu
China	Northbridge University of Shanghai	4491	Guardian	student04491_china@student.synthetic.edu
Germany	Berlin Institute of Technology	6135	Father	student06135_germany@student.synthetic.edu
Germany	Highland Germany International College	11053	Father	student11053_germany@student.synthetic.edu
Indonesia	Jakarta Institute of Technology	6648	Father	student06648_indonesia@student.synthetic.edu
Japan	Highland Japan International College	6509	Mother	student06509_japan@student.synthetic.edu
Japan	Riverstone Japan Metropolitan University	4376	Father	student04376_japan@student.synthetic.edu
Laos	Northbridge University of Vientiane	3439	Mother	student03439_laos@student.synthetic.edu
Mexico	Riverstone Mexico Metropolitan University	4235	Mother	student04235_mexico@student.synthetic.edu
Morocco	Northbridge University of Casablanca	252	Father	student00252_morocco@student.synthetic.edu
Nepal	Kathmandu Institute of Technology	4499	Guardian	student04499_nepal@student.synthetic.edu

30 filas

3. ¿Qué universidades presentan un nivel promedio de adicción digital entre sus estudiantes superior al promedio global de toda la red, por país y por universidad, mostrando primero las que tienen el promedio más alto?

	Pais	Universidad	Adiccion_Promedio	Evaluaciones
1	UK	Highland United Kingdom International College	19.91	474
2	Japan	Tokyo Institute of Technology	19.68	480
3	Germany	Riverstone Germany Metropolitan University	19.57	474
4	Germany	Berlin Institute of Technology	19.39	480
5	UK	Riverstone United Kingdom Metropolitan University	19.33	474
6	UK	London Institute of Technology	19.22	480
7	Canada	Northbridge University of Toronto	19.01	486
8	France	Paris Institute of Technology	19.00	486
9	USA	New York Institute of Technology	18.98	480
10	Japan	Northbridge University of Tokyo	18.80	480
11	Switzerland	Northbridge University of Zurich	18.73	480
12	Germany	Highland Germany International College	18.71	474
13	France	Northbridge University of Paris	18.59	486
14	USA	Northbridge University of New York	18.56	480
15	Denmark	Northbridge University of Copenhagen	18.55	492

92 filas

4. ¿Cuáles son las 3 universidades cuyos estudiantes concentran el mayor gasto digital acumulado?

Universidad	Pais	Gasto_Digital_Acumulado
Northbridge University of Toronto	Canada	41270.99
Northbridge University of Dubai	UAE	41247.14
Riverstone Japan Metropolitan University	Japan	41137.59

3 filas

5. ¿Qué programas académicos registrados en el catálogo maestro se encuentran disponibles para la asignación de evaluaciones, pero no presentan registros de datos recolectados a la fecha?

Carrera_id	Carrera
7	Architecture
14	Bioinformatics
11	Civil Engineering
8	Data Science
12	History
13	Marketing
10	Psychology
9	Quantum Computing
15	Sustainable Urbanism

9 filas

- **M2: Trazando conexiones**

1. ¿Qué estudiantes muestran un empeoramiento en su comportamiento digital entre una encuesta y la siguiente?

	student_id	university_name	country_name	encuesta_anterior	encuesta_actual	brain_rot_anterior	brain_rot_actual	aumento_brain_rot
1	194	Highland South Korea International College	South Korea	3	4	34.90	44.90	10.00
2	529	Dar es Salaam Institute of Technology	Tanzania	3	4	29.10	39.10	10.00
3	647	Riverstone India Metropolitan University	India	5	6	11.80	21.80	10.00
4	661	Riverstone Netherlands Metropolitan University	Netherlands	5	6	37.50	47.50	10.00
5	711	Highland Indonesia International College	Indonesia	5	6	18.60	28.60	10.00
6	1121	Highland China International College	China	2	3	10.80	20.80	10.00
7	1158	Northbridge University of Manila	Philippines	3	4	32.70	42.70	10.00
8	1222	Highland Brazil International College	Brazil	3	4	37.70	47.70	10.00
9	1408	Highland Brazil International College	Brazil	2	3	34.70	44.70	10.00
10	1466	Singapore Institute of Technology	Singapore	5	6	23.60	33.60	10.00
11	1727	Mexico City Institute of Technology	Mexico	4	5	26.10	36.10	10.00
12	1768	Istanbul Institute of Technology	Turkey	5	6	22.20	32.20	10.00
13	1780	Cape Town Institute of Technology	South Africa	5	6	23.00	33.00	10.00
14	1830	Riverstone Philippines Metropolitan University	Philippines	3	4	38.80	48.80	10.00
15	2415	Highland South Korea International College	South Korea	4	5	30.10	40.10	10.00
16	2435	Riverstone Sweden Metropolitan University	Sweden	5	6	39.70	49.70	10.00
17	2456	Mumbai Institute of Technology	India	1	2	31.40	41.40	10.00

100 filas

2. ¿Cuál es el perfil completo de cada evaluación estudiantil, considerando al estudiante, su universidad, país, carrera, período académico, dispositivo utilizado y principales resultados?

Assessment_id	student_id	university_name	country_name	Development_level_name	Period_year	period_term	field_of_study	Device_name	education_level	urban_rural	digital_addiction_score	brain_rot_level	class_attendance_rate	study_h
16	5904	New York Institute of Technology	USA	Developed	2025	2	STEM	Smartphone	Undergraduate	Urban	44.00	49.20	85.10	29.40
17	83339	Riverstone UAE Metropolitan University	UAE	Developed	2025	2	Law	Smartphone	Undergraduate	Urban	44.00	51.10	83.00	18.60
18	76068	Highland China International College	China	Developed	2025	2	Law	PC	Undergraduate	Rural	43.80	52.70	85.40	23.00
19	37907	Northbridge University of Bucharest	Romania	Developed	2025	2	Law	Smartphone	Undergraduate	Urban	43.70	44.70	83.70	14.80
20	37908	Northbridge University of Bucharest	Romania	Developed	2025	2	Law	Smartphone	Undergraduate	Urban	43.60	43.80	79.40	13.70
21	10224	Highland France International College	France	Developed	2025	2	STEM	Laptop	Undergraduate	Urban	43.50	56.40	79.20	13.40
22	83340	Riverstone UAE Metropolitan University	UAE	Developed	2025	2	Law	Smartphone	Undergraduate	Urban	43.50	46.60	80.70	19.70
23	3642	Northbridge University of Paris	France	Developed	2025	2	Arts	Smartphone	Undergraduate	Urban	43.40	51.00	85.10	35.00
24	83928	Northbridge University of Paris	France	Developed	2025	2	STEM	PC	Undergraduate	Urban	43.30	45.60	84.00	16.70
25	86736	New York Institute of Technology	USA	Developed	2025	2	Social Sciences	Smartphone	Undergraduate	Rural	43.30	43.50	97.40	27.70
26	63486	Riverstone Japan Metropolitan University	Japan	Developed	2025	2	Business	Smartphone	Undergraduate	Urban	43.20	42.00	95.90	25.00
27	83052	Riverstone China Metropolitan University	China	Developed	2025	2	Social Sciences	Smartphone	Undergraduate	Rural	43.10	41.20	99.00	21.00
28	27309	Warsaw Institute of Technology	Poland	Developed	2025	1	Social Sciences	Smartphone	Undergraduate	Urban	42.90	46.90	87.00	28.20
29	30484	Riverstone Philippines Metropolitan University	Philippines	Developed	2025	2	Business	Smartphone	Undergraduate	Urban	42.80	49.20	97.60	22.10
30	55260	Highland New Zealand International College	New Zealand	Developed	2025	2	Law	Smartphone	Undergraduate	Rural	42.80	48.10	86.90	12.90
31	49884	Bucharest Institute of Technology	Romania	Developed	2025	2	Arts	Smartphone	Undergraduate	Rural	42.80	32.90	85.30	17.80
32	85104	Tokyo Institute of Technology	Japan	Developed	2025	2	Social Sciences	Smartphone	Undergraduate	Rural	42.70	63.00	88.30	12.50

200 filas

3. ¿Qué universidades presentan un nivel promedio de riesgo digital mayor al promedio general del sistema y mayor al promedio de su propio país?

	university_name	country_name	total_evaluaciones	promedio_adiccion_universid...	promedio_adiccion_pais	promedio_adiccion_siste...	diferencia_contra_siste...	diferencia_contra_pais
4	Berlin Institute of Technology	Germany	480	19.392500	18.964150	15.783054	3.609446	0.428350
5	Riverstone United Kingdom Metropolitan Univers...	UK	474	19.334177	19.220597	15.783054	3.551123	0.113580
6	Northbridge University of Toronto	Canada	486	19.007818	18.144495	15.783054	3.224764	0.863323
7	Paris Institute of Technology	France	486	18.996913	18.255195	15.783054	3.213859	0.741718
8	New York Institute of Technology	USA	480	18.978541	18.481875	15.783054	3.195487	0.496666
9	Northbridge University of Zurich	Switzerland	480	18.727708	18.394444	15.783054	2.944654	0.332664
10	Northbridge University of Paris	France	486	18.591975	18.255195	15.783054	2.808921	0.336780
11	Northbridge University of New York	USA	480	18.561041	18.481875	15.783054	2.777987	0.079166
12	Northbridge University of Copenhagen	Denmark	492	18.554065	17.662436	15.783054	2.771011	0.891629
13	Northbridge University of Oslo	Norway	474	18.517932	17.627388	15.783054	2.734878	0.890544
14	Highland Switzerland International College	Switzerland	474	18.502531	18.394444	15.783054	2.719477	0.108087
15	Riverstone Switzerland Metropolitan University	Switzerland	474	18.452742	18.394444	15.783054	2.669688	0.058298
16	Copenhagen Institute of Technology	Denmark	492	18.423780	17.662436	15.783054	2.640726	0.761344
17	Highland New Zealand International College	New Zealand	486	18.183333	17.434000	15.783054	2.400279	0.749333
18	Amsterdam Institute of Technology	Netherlands	468	18.170726	17.414323	15.783054	2.387672	0.756403
19	Riverstone Denmark Metropolitan University	Denmark	492	17.981910	17.662436	15.783054	2.198856	0.319474
20	Stockholm Institute of Technology	Sweden	486	17.932716	17.250102	15.783054	2.149662	0.682614

51 filas

4. ¿Qué universidades no registraron casos críticos de riesgo digital durante el período 2025-2?

	university_name	country_name	evaluaciones_2025_2	mayor_adiccion_2025_2
1	Northbridge University of La Paz	Bolivia	279	30.60
2	Northbridge University of Phnom Penh	Cambodia	279	33.90
3	Phnom Penh Institute of Technology	Cambodia	279	32.00
4	Highland Chile International College	Chile	225	34.20
5	Riverstone Chile Metropolitan University	Chile	225	33.20
6	Santiago Institute of Technology	Chile	228	32.30
7	Shanghai Institute of Technology	China	234	34.90
8	Highland Denmark International College	Denmark	243	32.60
9	Addis Ababa Institute of Technology	Ethiopia	270	32.70
10	Northbridge University of Addis Ababa	Ethiopia	270	34.10
11	Riverstone Ethiopia Metropolitan University	Ethiopia	270	33.00
12	Accra Institute of Technology	Ghana	270	30.80
13	Northbridge University of Accra	Ghana	270	31.70
14	Highland India International College	India	237	34.40
15	Riverstone India Metropolitan University	India	237	31.10
16	Northbridge University of Jakarta	Indonesia	234	34.80
17	Riverstone Indonesia Metropolitan University	Indonesia	231	33.50

47 filas

- ¿Qué países tienen casos críticos de riesgo digital en todas sus universidades durante el período 2025-2?

Resultados		Mensajes	
	country_name	universidades_del_pais	casos_criticos_2025_2
1	Argentina	4	17
2	Australia	4	20
3	Bangladesh	3	11
4	Brazil	4	19
5	Canada	4	18
6	France	4	22
7	Germany	4	19
8	Japan	4	21
9	Netherlands	4	23
10	Norway	4	18
11	Oman	4	21
12	Saudi Arabia	4	8
13	Singapore	4	22
14	South Korea	4	18
15	Sweden	4	16

20 filas

- M3: Midiendo el tiempo

- ¿Cuál es el tiempo promedio de respuesta a las encuestas (medido como la diferencia entre sent_date y reception_date) por universidad y campo de estudio? ¿Qué combinaciones presentan el mayor tiempo de respuesta dentro de cada universidad?

	university_name	field_of_study	total_respuestas	tiempo_promedio_dias	mayor_ranking	orden_prioridad	estado
1	Accra Institute of Technology	Medicine	102	5	1	1	Priorizar
2	Accra Institute of Technology	STEM	96	5	1	2	Revisión posterior
3	Accra Institute of Technology	Business	84	5	1	3	Revisión posterior
4	Accra Institute of Technology	Social Sciences	78	5	1	4	Revisión posterior
5	Accra Institute of Technology	Arts	60	5	1	5	Revisión posterior
6	Addis Ababa Institute of Technology	Medicine	114	5	1	1	Priorizar
7	Addis Ababa Institute of Technology	STEM	90	5	1	2	Revisión posterior
8	Addis Ababa Institute of Technology	Business	78	5	1	3	Revisión posterior
9	Addis Ababa Institute of Technology	Social Sciences	66	5	1	4	Revisión posterior
10	Almaty Institute of Technology	Business	96	5	1	1	Priorizar
11	Almaty Institute of Technology	Social Sciences	90	5	1	2	Revisión posterior
12	Almaty Institute of Technology	STEM	66	5	1	3	Revisión posterior
13	Almaty Institute of Technology	Medicine	60	5	1	4	Revisión posterior
14	Almaty Institute of Technology	Arts	54	5	1	5	Revisión posterior
15	Amsterdam Institute of Technology	Law	90	5	1	1	Priorizar

563 filas

- ¿Qué porcentaje de las respuestas de cada universidad se completa dentro de los últimos 5 días antes del límite de respuesta de la encuesta (sent_date + 10 días), y cuántos días en promedio les quedan a los estudiantes de cada universidad al momento de responder?

	university_name	total_respuestas	respuestas_cercanas_al_cierre	porcentaje_cercanas	promedio_dias_restantes_al_limite
1	Riverstone Germany Metropolitan University	474	282	59.49%	4
2	Riverstone Singapore Metropolitan University	474	281	59.28%	4
3	Northbridge University of Amsterdam	474	280	59.07%	4
4	Cape Town Institute of Technology	462	271	58.66%	4
5	Riverstone Kazakhstan Metropolitan University	450	262	58.22%	4
6	Auckland Institute of Technology	486	282	58.02%	4
7	Highland Sweden International College	486	282	58.02%	4
8	Northbridge University of Bangkok	450	261	58.00%	4
9	Highland South Korea International College	480	278	57.92%	4
10	Northbridge University of Istanbul	456	264	57.89%	4
11	Northbridge University of Vientiane	534	309	57.87%	4
12	Seoul Institute of Technology	480	277	57.71%	4
13	Northbridge University of Warsaw	462	265	57.36%	4
14	Highland Turkey International College	450	258	57.33%	4
15	Highland Kazakhstan International College	450	258	57.33%	4

185 filas

- ¿En qué categoría de desempeño (Rápida, Moderada, Lenta) se clasifica cada universidad según su tiempo promedio de respuesta, y qué tipo de seguimiento operativo le corresponde según esa categoría?

	university_name	promedio_dias	clasificacion
1	Riverstone France Metropolitan University	4.660493	Rápida
2	Riverstone Malaysia Metropolitan University	4.670995	Rápida
3	Riverstone Chile Metropolitan University	4.700000	Rápida
4	Lahore Institute of Technology	4.720430	Rápida
5	Riverstone Sweden Metropolitan University	4.744855	Rápida
6	Northbridge University of Casablanca	4.753703	Rápida
7	Northbridge University of Paris	4.763374	Rápida
8	Highland Canada International College	4.765432	Rápida
9	Highland Chile International College	4.766666	Rápida
10	Northbridge University of Shanghai	4.769230	Rápida
11	Northbridge University of Accra	4.775925	Rápida
12	Northbridge University of Lima	4.807116	Rápida
13	Highland India International College	4.808016	Rápida
14	Northbridge University of Auckland	4.808943	Rápida
15	Riverstone Morocco Metropolitan University	4.810861	Rápida

185 filas

4. ¿Cuántas encuestas recibió cada universidad exactamente en el corte de mitad de mes (día 15) de cada ciclo de encuesta (primera, segunda o tercera), cuál fue el acumulado de respuestas hasta esa fecha, y cómo varió ese avance respecto al ciclo anterior de la misma universidad?

	university_name	periodo	num_encuesta	mes	dia_corte	num_encuestas_al_dia_corte	acumulado_hasta_dia_corte	total_respuestas_mes	porcentaje_numerico	porcentaje_avance_hasta_corte	variacion_encuesta_anterior
1	Accra Institute of Technology	2025-1	Primera encuesta	3	15	12	66	90	0.7333333333333333	73.33%	Primera encuesta
2	Accra Institute of Technology	2025-1	Segunda encuesta	5	15	9	69	90	0.7666666666666666	76.67%	3.33%
3	Accra Institute of Technology	2025-1	Tercera encuesta	7	15	11	63	90	0.7000000000000000	70.00%	-6.67%
4	Accra Institute of Technology	2025-2	Primera encuesta	8	15	11	62	90	0.6888888888888888	68.89%	-1.11%
5	Accra Institute of Technology	2025-2	Segunda encuesta	10	15	7	61	90	0.6777777777777777	67.78%	-1.11%
6	Accra Institute of Technology	2025-2	Tercera encuesta	12	15	5	55	90	0.6111111111111111	61.11%	-6.67%
7	Addis Ababa Institute of Technology	2025-1	Primera encuesta	3	15	9	65	90	0.7222222222222222	72.22%	Primera encuesta
8	Addis Ababa Institute of Technology	2025-1	Segunda encuesta	5	15	13	73	90	0.8111111111111111	81.11%	8.89%
9	Addis Ababa Institute of Technology	2025-1	Tercera encuesta	7	15	10	65	90	0.7222222222222222	72.22%	-8.89%
10	Addis Ababa Institute of Technology	2025-2	Primera encuesta	8	15	7	67	90	0.7444444444444444	74.44%	2.22%
11	Addis Ababa Institute of Technology	2025-2	Segunda encuesta	10	15	2	62	90	0.6888888888888888	68.89%	-5.56%
12	Addis Ababa Institute of Technology	2025-2	Tercera encuesta	12	15	10	66	90	0.7333333333333333	73.33%	4.44%
13	Almaty Institute of Technology	2025-1	Primera encuesta	3	15	6	51	76	0.6710526315789473	67.11%	Primera encuesta
14	Almaty Institute of Technology	2025-1	Segunda encuesta	5	15	6	54	76	0.710526315789473	71.05%	3.95%
15	Almaty Institute of Technology	2025-1	Tercera encuesta	7	15	7	50	76	0.657894736842105	65.79%	-5.26%

1110 filas

5. ¿A qué trimestre calendario (etiquetado como "2025-T1") pertenece cada respuesta recibida, y qué porcentaje del total de respuestas de cada universidad representa cada trimestre?

	university_name	trimestre	total_encuestas	total_universidad	porcentaje_sin_format	promedio_dias_para_fin_mes	porcentaje_del_total	ranking_menor_participacion
1	Accra Institute of Technology	2025-T1	90	540	0.1666666666666666	17	16.67%	1
2	Accra Institute of Technology	2025-T2	90	540	0.1666666666666666	18	16.67%	1
3	Accra Institute of Technology	2025-T3	180	540	0.3333333333333333	17	33.33%	2
4	Accra Institute of Technology	2025-T4	180	540	0.3333333333333333	17	33.33%	2
5	Addis Ababa Institute of Technology	2025-T1	90	540	0.1666666666666666	17	16.67%	1
6	Addis Ababa Institute of Technology	2025-T2	90	540	0.1666666666666666	18	16.67%	1
7	Addis Ababa Institute of Technology	2025-T3	180	540	0.3333333333333333	17	33.33%	2
8	Addis Ababa Institute of Technology	2025-T4	180	540	0.3333333333333333	18	33.33%	2
9	Almaty Institute of Technology	2025-T1	76	456	0.1666666666666666	17	16.67%	1
10	Almaty Institute of Technology	2025-T2	76	456	0.1666666666666666	17	16.67%	1
11	Almaty Institute of Technology	2025-T3	152	456	0.3333333333333333	17	33.33%	2
12	Almaty Institute of Technology	2025-T4	152	456	0.3333333333333333	17	33.33%	2
13	Amsterdam Institute of Technology	2025-T1	78	468	0.1666666666666666	18	16.67%	1
14	Amsterdam Institute of Technology	2025-T2	78	468	0.1666666666666666	18	16.67%	1
15	Amsterdam Institute of Technology	2025-T3	156	468	0.3333333333333333	18	33.33%	2

740 filas

- M4:

1. ¿Cuáles son las N evaluaciones estudiantiles con el valor más alto dentro de cada métrica?

	categoria_metrica	nombre_metrica	unidad	posicion	evaluacion_id	numero_encuesta	estudiante_id	usuario_estudiante	campo_estudio	año_periodo	ciclo_periodo	valor_metrica
1	academic	academic_motivation	score_1_10	1	85	1	15	student00015_france	Law	2025	1	10.00
2	academic	academic_motivation	score_1_10	2	86	2	15	student00015_france	Law	2025	1	10.00
3	academic	academic_motivation	score_1_10	3	88	4	15	student00015_france	Law	2025	2	10.00
4	academic	academic_motivation	score_1_10	4	385	1	65	student00065_kenya	Arts	2025	1	10.00
5	academic	attention_span_minutes	minutes	1	498	6	83	student00083_denmark	Business	2025	2	91.40
6	academic	attention_span_minutes	minutes	2	8933	5	1489	student01489_cambodia	Medicine	2025	2	91.20
7	academic	attention_span_minutes	minutes	3	24714	6	4119	student04119_usa	STEM	2025	2	89.70
8	academic	attention_span_minutes	minutes	4	43614	6	7269	student07269_new_zealand	STEM	2025	2	88.40
9	academic	class_attendance_rate	percent	1	7	1	2	student00002_turkey	Arts	2025	1	100.00
10	academic	class_attendance_rate	percent	2	19	1	4	student00004_qatar	Medicine	2025	1	100.00
11	academic	class_attendance_rate	percent	3	20	2	4	student00004_qatar	Medicine	2025	1	100.00
12	academic	class_attendance_rate	percent	4	21	3	4	student00004_qatar	Medicine	2025	1	100.00
13	academic	study_hours_per_week	hours_per...	1	81450	6	13575	student13575_china	Law	2025	2	47.00
14	academic	study_hours_per_week	hours_per...	2	7818	6	1303	student01303_kenya	STEM	2025	2	47.00
15	academic	study_hours_per_week	hours_per...	3	7817	5	1303	student01303_kenya	STEM	2025	2	46.80
16	academic	study_hours_per_week	hours_per...	4	7816	4	1303	student01303_kenya	STEM	2025	2	46.30
17	advertising	ads_clicked_per_week	count_per...	1	32616	6	5436	student05436_bolivia	Medicine	2025	2	41.00
18	advertising	ads_clicked_per_week	count_per...	2	52470	6	8745	student08745_australia	Business	2025	2	40.00
19	advertising	ads_clicked_per_week	count_per...	3	32615	5	5436	student05436_bolivia	Medicine	2025	2	38.00
20	advertising	ads_clicked_per_week	count_per...	4	34014	6	5669	student05669_germany	Medicine	2025	2	38.00
21	advertising	ads_viewed_per_day	count_per...	1	83807	5	13968	student13968_sweden	Social Scien...	2025	2	255.00
22	advertising	ads_viewed_per_day	count_per...	2	83808	6	13968	student13968_sweden	Social Scien...	2025	2	253.00

128 filas

2. ¿Qué posición ocupa cada estudiante dentro de su campo de estudio según el promedio obtenido en cada métrica durante cada periodo académico?

Resultados Mensajes

	categoria_metrica	nombre_metrica	unidad	año_periodo	ciclo_periodo	campo_estudio	estudiante_id	promedio_metrica	posicion
1	academic	academic_motivation	score_1_10	2025	1	Arts	2405	10.00	1
2	academic	academic_motivation	score_1_10	2025	1	Arts	8405	10.00	1
3	academic	academic_motivation	score_1_10	2025	1	Arts	7521	10.00	1
4	academic	academic_motivation	score_1_10	2025	1	Arts	13398	10.00	1
5	academic	academic_motivation	score_1_10	2025	1	Arts	952	10.00	1
6	academic	academic_motivation	score_1_10	2025	1	Arts	65	10.00	1
7	academic	academic_motivation	score_1_10	2025	1	Arts	8389	9.97	2
8	academic	academic_motivation	score_1_10	2025	1	Arts	7014	9.97	2
9	academic	academic_motivation	score_1_10	2025	1	Arts	5548	9.97	2
10	academic	academic_motivation	score_1_10	2025	1	Arts	533	9.93	3
11	academic	academic_motivation	score_1_10	2025	1	Arts	13456	9.93	3
12	academic	academic_motivation	score_1_10	2025	1	Arts	11321	9.90	4
13	academic	academic_motivation	score_1_10	2025	1	Arts	11748	9.90	4
14	academic	academic_motivation	score_1_10	2025	1	Arts	12195	9.90	4
15	academic	academic_motivation	score_1_10	2025	1	Arts	7307	9.83	5
16	academic	academic_motivation	score_1_10	2025	1	Arts	4624	9.83	5
17	academic	academic_motivation	score_1_10	2025	1	Arts	10500	9.70	6
18	academic	academic_motivation	score_1_10	2025	1	Arts	11702	9.70	6
19	academic	academic_motivation	score_1_10	2025	1	Arts	2130	9.67	7
20	academic	academic_motivation	score_1_10	2025	1	Arts	15000	9.63	8
21	academic	academic_motivation	score_1_10	2025	1	Arts	1582	9.63	8
22	academic	academic_motivation	score_1_10	2025	1	Arts	3588	9.43	9

960,000 filas

3. ¿Cómo varió la última medición de una métrica seleccionada para cada estudiante respecto a su última medición del periodo académico anterior? (Se tomó la última encuesta del periodo anterior con la última encuesta del periodo siguiente)

Resultados															Mensajes
	categoria_metrica	nombre_metrica	unidad	carrera	estudiante_id	usuario_estudiante	año_periodo_anterior	ciclo_periodo_anterior	encuesta_anterior	valor_anterior	año_periodo_actual	ciclo_periodo_actual	encuesta_actual	valor_actual	variacion_respecto_anterior
1	digital_behavior	average_session_length_minutes	minutes	Arts	2	student00002_turkey	2025	1	3	35.00	2025	2	6	52.00	17.00
2	digital_behavior	average_session_length_minutes	minutes	Arts	18	student00018_gatar	2025	1	3	50.00	2025	2	6	90.00	40.00
3	digital_behavior	average_session_length_minutes	minutes	Arts	24	student00024_south_korea	2025	1	3	34.00	2025	2	6	26.00	-8.00
4	digital_behavior	average_session_length_minutes	minutes	Arts	27	student00027_malaysia	2025	1	3	30.00	2025	2	6	47.00	17.00
5	digital_behavior	average_session_length_minutes	minutes	Arts	29	student00029_juwaat	2025	1	3	29.00	2025	2	6	18.00	-11.00
6	digital_behavior	average_session_length_minutes	minutes	Arts	45	student00045_philippines	2025	1	3	32.00	2025	2	6	27.00	-5.00
7	digital_behavior	average_session_length_minutes	minutes	Arts	50	student00050_canada	2025	1	3	38.00	2025	2	6	31.00	-7.00
8	digital_behavior	average_session_length_minutes	minutes	Arts	53	student00053_gatar	2025	1	3	26.00	2025	2	6	22.00	-4.00
9	digital_behavior	average_session_length_minutes	minutes	Arts	55	student00055_canada	2025	1	3	44.00	2025	2	6	44.00	0.00
10	digital_behavior	average_session_length_minutes	minutes	Arts	62	student00062_sweden	2025	1	3	57.00	2025	2	6	90.00	33.00
11	digital_behavior	average_session_length_minutes	minutes	Arts	65	student00065_kenya	2025	1	3	37.00	2025	2	6	40.00	3.00
12	digital_behavior	average_session_length_minutes	minutes	Arts	66	student00066_poland	2025	1	3	45.00	2025	2	6	25.00	-20.00
13	digital_behavior	average_session_length_minutes	minutes	Arts	78	student00078_uk	2025	1	3	35.00	2025	2	6	47.00	12.00
14	digital_behavior	average_session_length_minutes	minutes	Arts	79	student00079_juwaat	2025	1	3	42.00	2025	2	6	34.00	-8.00
15	digital_behavior	average_session_length_minutes	minutes	Arts	93	student00093_cambodia	2025	1	3	41.00	2025	2	6	35.00	-6.00
16	digital_behavior	average_session_length_minutes	minutes	Arts	103	student00103_turkey	2025	1	3	62.00	2025	2	6	90.00	28.00
17	digital_behavior	average_session_length_minutes	minutes	Arts	115	student00115_australia	2025	1	3	25.00	2025	2	6	22.00	-3.00
18	digital_behavior	average_session_length_minutes	minutes	Arts	118	student00118_bangladesh	2025	1	3	28.00	2025	2	6	34.00	6.00
19	digital_behavior	average_session_length_minutes	minutes	Arts	123	student00123_romania	2025	1	3	55.00	2025	2	6	70.00	15.00
20	digital_behavior	average_session_length_minutes	minutes	Arts	129	student00129_tanzania	2025	1	3	16.00	2025	2	6	13.00	-3.00
21	digital_behavior	average_session_length_minutes	minutes	Arts	145	student00145_bolivia	2025	1	3	28.00	2025	2	6	25.00	-3.00
22	digital_behavior	average_session_length_minutes	minutes	Arts	152	student00152_brazil	2025	1	3	34.00	2025	2	6	47.00	13.00

Consulta ejecutada correctamente.

DESKTOP-LBIFLLZ\SQLEXPRESS ... DESKTOP-LBIFLLZ\USER (74) StudentDigitalBehaviorDB 00:00:00 15,000 filas

15,000 filas

4. ¿Cuál es el total acumulado de una métrica seleccionada a lo largo de las encuestas de un periodo académico?

Resultados		Mensajes								
	nombre_metrica	año_periodo	ciclo_periodo	numero_encuesta	total_encuesta	total_periodo	total_acumulado	porcentaje_del_periodo	porcentaje_acumulado	
1	short_video_hours	2025	1	1	22166.43	68689.43	22166.43	32.27%	32.27%	
2	short_video_hours	2025	1	2	22934.10	68689.43	45100.53	33.39%	65.66%	
3	short_video_hours	2025	1	3	23588.90	68689.43	68689.43	34.34%	100.00%	
4	short_video_hours	2025	2	4	24366.90	75318.00	24366.90	32.35%	32.35%	
5	short_video_hours	2025	2	5	25084.90	75318.00	49451.80	33.31%	65.66%	
6	short_video_hours	2025	2	6	25866.20	75318.00	75318.00	34.34%	100.00%	

6 filas

5. ¿Qué porcentaje del total global de una métrica seleccionada representa cada carrera y qué porcentaje representa dentro de cada periodo académico?

Resultados		Mensajes						
	nombre_metrica	año_periodo	ciclo_periodo	carrera	total_carrera	porcentaje_total_global	porcentaje_dentro_periodo	
1	average_session_length_minutes	2025	1	Medicine	264548.00	8.57%	17.85%	
2	average_session_length_minutes	2025	1	Law	250330.00	8.11%	16.89%	
3	average_session_length_minutes	2025	1	STEM	248199.00	8.04%	16.75%	
4	average_session_length_minutes	2025	1	Social Sciences	246314.00	7.98%	16.62%	
5	average_session_length_minutes	2025	1	Business	236486.00	7.66%	15.96%	
6	average_session_length_minutes	2025	1	Arts	235900.00	7.64%	15.92%	
7	average_session_length_minutes	2025	2	Medicine	285686.00	9.25%	17.79%	
8	average_session_length_minutes	2025	2	Law	273280.00	8.85%	17.02%	
9	average_session_length_minutes	2025	2	STEM	268584.00	8.70%	16.72%	
10	average_session_length_minutes	2025	2	Social Sciences	264509.00	8.57%	16.47%	
11	average_session_length_minutes	2025	2	Arts	257964.00	8.35%	16.06%	
12	average_session_length_minutes	2025	2	Business	256000.00	8.29%	15.94%	

M5: Construyendo el reporte

- ¿Cómo evoluciona el nivel de riesgo digital de los estudiantes en cada encuesta, considerando el digital_addiction_score como indicador principal de uso problemático de medios digitales?

	survey_number	riesgo_bajo	riesgo_medio	riesgo_alto
1	1	14999	1	0
2	2	14999	1	0
3	3	14997	3	0
4	4	14982	18	0
5	5	14975	25	0
6	6	14939	61	0

2. ¿Cómo se comparan los principales indicadores académicos y de bienestar por carrera, transformando los promedios de asistencia, productividad y bienestar en un formato normalizado para facilitar su análisis y visualización?

	field_of_study	indicador	valor_promedio
1	Arts	promedio_asistencia	90.36
2	Arts	promedio_bienestar	53.34
3	Arts	promedio_productividad	8.45
4	Business	promedio_asistencia	90.32
5	Business	promedio_bienestar	53.80
6	Business	promedio_productividad	8.47
7	Law	promedio_asistencia	90.51
8	Law	promedio_bienestar	53.82
9	Law	promedio_productividad	8.49
10	Medicine	promedio_asistencia	90.31
11	Medicine	promedio_bienestar	53.74
12	Medicine	promedio_productividad	8.46
13	Social Scien...	promedio_asistencia	90.55
14	Social Scien...	promedio_bienestar	54.20
15	Social Scien...	promedio_productividad	8.50
16	STEM	promedio_asistencia	90.28
17	STEM	promedio_bienestar	54.07
18	STEM	promedio_productividad	8.45

3. ¿Cuántas encuestas ha acumulado cada universidad desde el inicio del año, del trimestre y del mes hasta una fecha de corte, para evaluar el avance de recolección de datos en el reporte ejecutivo?

	university_name	total_estudiantes	encuestas_ytd	encuestas_qtd	encuestas_mtd
1	Dubai Institute of Technology	98	294	98	98
2	Northbridge University of Dubai	98	294	98	98
3	Riverstone UAE Metropolitan University	97	291	97	97
4	La Paz Institute of Technology	93	279	93	93
5	Lahore Institute of Technology	93	279	93	93
6	Northbridge University of La Paz	93	279	93	93
7	Northbridge University of Lahore	93	279	93	93
8	Northbridge University of Phnom Penh	93	279	93	93
9	Phnom Penh Institute of Technology	93	279	93	93
10	Riverstone Bolivia Metropolitan Univer...	93	279	93	93
11	Northbridge University of Dhaka	92	276	92	92
12	Riverstone Cambodia Metropolitan U...	92	276	92	92
13	Riverstone Pakistan Metropolitan Univ...	92	276	92	92
14	Dhaka Institute of Technology	91	273	91	91
15	Lagos Institute of Technology	91	273	91	91

4. ¿Qué estudiantes deben ser priorizados dentro de cada universidad según su nivel relativo de riesgo, usando cuartiles y percentiles calculados a partir de indicadores de adicción digital, estrés y bienestar?

	university_name	student_id	survey_number	score_riesgo	cuartil_riesgo	percent_rank_riesgo
1	Kuala Lumpur Institute of Technology	5156	6	63.63	1	1.0000
2	Kuala Lumpur Institute of Technology	14024	6	62.13	1	0.9870
3	Kuala Lumpur Institute of Technology	8335	6	61.17	1	0.9740
4	Kuala Lumpur Institute of Technology	655	6	60.77	1	0.9610
5	Kuala Lumpur Institute of Technology	1777	6	57.07	1	0.9481
6	Kuala Lumpur Institute of Technology	1075	6	55.90	1	0.9351
7	Kuala Lumpur Institute of Technology	7633	6	55.70	1	0.9221
8	Kuala Lumpur Institute of Technology	10149	6	55.40	1	0.9091
9	Kuala Lumpur Institute of Technology	12970	6	54.83	1	0.8961
10	Kuala Lumpur Institute of Technology	6285	6	54.60	1	0.8831
11	Kuala Lumpur Institute of Technology	6127	6	54.33	1	0.8701
12	Kuala Lumpur Institute of Technology	12016	6	54.23	1	0.8571
13	Kuala Lumpur Institute of Technology	11181	6	51.00	1	0.8442
14	Kuala Lumpur Institute of Technology	11077	6	49.73	1	0.8312
15	Kuala Lumpur Institute of Technology	11151	6	47.53	1	0.8182
16	Kuala Lumpur Institute of Technology	6878	6	47.07	1	0.8052
17	Kuala Lumpur Institute of Technology	6115	6	46.50	1	0.7922
18	Kuala Lumpur Institute of Technology	12731	6	46.27	1	0.7792
19	Kuala Lumpur Institute of Technology	8930	6	46.03	1	0.7662
20	Kuala Lumpur Institute of Technology	4367	6	46.00	1	0.7532

50 filas

5. ¿Qué universidades de un país y periodo específico superan un umbral mínimo de asistencia, considerando también sus niveles promedio de productividad, bienestar y adicción digital?

	country_name	university_name	Period_year	period_term	total_estudiantes	promedio_asistencia	promedio_productividad	promedio_bienestar	promedio_adiccion_digital
1	Malaysia	Riverstone Malaysia Metropolitan University	2025	1	77	91.87	9.09	60.00	12.80
2	Malaysia	Northbridge University of Kuala Lumpur	2025	1	78	91.74	8.80	57.10	13.89
3	Malaysia	Highland Malaysia International College	2025	1	77	91.63	8.61	60.47	13.24
4	Malaysia	Kuala Lumpur Institute of Technology	2025	1	78	91.62	9.20	59.59	13.27

10. Creación procedimiento básicos

10.1 Procedimiento 1:

Objetivo: Este procedimiento genera un reporte ejecutivo consolidado de indicadores académicos y de bienestar. Permite filtrar por país, año y periodo académico, además de establecer un umbral mínimo de asistencia para la toma de decisiones estratégicas, tal como se especifica en el requerimiento RF-12.

Ejecución y Verificación

Para validar el funcionamiento, se ejecutó el reporte para el caso de estudio de Malasia en el primer periodo de 2025:


	country_name	university_name	Period_year	period_term	total_estudiantes	promedio_asistencia	promedio_productividad	promedio_bienestar	promedio_adiccion_digital
1	Malaysia	Riverstone Malaysia Metropolitan University	2025	1	77	91.87	9.09	60.00	12.80
2	Malaysia	Northbridge University of Kuala Lumpur	2025	1	78	91.74	8.80	57.10	13.89
3	Malaysia	Highland Malaysia International College	2025	1	77	91.63	8.61	60.47	13.24
4	Malaysia	Kuala Lumpur Institute of Technology	2025	1	78	91.62	9.20	59.59	13.27

10.2 Procedimiento 2:


Objetivo: Implementar un control de calidad de datos preventivo para verificar la integridad de los expedientes estudiantiles.



Da cumplimiento al requerimiento RNF-05 y RB-02, validando de forma proactiva que los registros de estudiantes posean la información geográfica y académica mínima necesaria antes de ser procesados por los modelos analíticos, previniendo así la propagación de datos nulos en los reportes.

Ejecución y Verificación



11. Creación de reportes de visualización en Python







12. Modelo predictivo de deserción estudiantil mediante regresión logística

Como parte de la evolución hacia la analítica predictiva, EduData Analytics desarrolló un modelo orientado a estimar el riesgo de deserción estudiantil mediante técnicas de aprendizaje supervisado.

El objetivo del modelo es transformar los datos históricos recopilados por las universidades con las que trabajamos en información anticipada que permita identificar estudiantes con mayor probabilidad de abandonar sus estudios y facilitar la implementación de estrategias preventivas.

Para esta primera iniciativa predictiva se empleó un modelo de Regresión logística dado que permite resolver problemas de clasificación binaria, estimar probabilidades de ocurrencia y proporcionar una interpretación precisa de los factores que se asocian al fenómeno estudiado.

En este caso, se definió como la variable objetivo al estado del estudiante:

- 0: Estudiante que continúa sus estudios
- 1: Estudiante que desertó

12.1 Preparación de datos y construcción del modelo

Para el tratamiento del modelo se utilizó una base histórica conformada por 308 281 registros de estudiantes y 46 variables, incluyendo información relacionado con:

- Características del entorno del estudiante
- Acceso a recurso tecnológicos
- Comportamiento académico
- Hábitos digitales
- Motivación
- Asistencia y desempeño

Debido a que la deserción representa una proporción menor dentro de la población estudiantil analizada (19.73%), mientras que los estudiantes que continúan representan el 80.72%, se aplicó una estrategia de balanceo durante el entrenamiento mediante ponderación de clases.

Esto permitió que el modelo otorgara mayor importancia a la detección de estudiantes desertores y evitara priorizar únicamente la clase mayoritaria.

12.2 Selección de variables predictoras

Al inicio, se consideró múltiples variables que se relacionan con la trayectoria estudiantil. Posteriormente, mediante análisis estadístico y empleando valores de significancia (p-value), se seleccionaron aquellas variables que presentaron mayor evidencia de relación con la deserción y un p-value mayor a 0.05.

Las variables finales incorporados al modelo fueron:

- porcentaje de pobreza
- índice de infraestructura de internet
- edad
- horas de acceso a internet
- motivación académica
- horas de contenido educativo
- nivel de distracción digital (brain rot level)
- capacidad de atención
- horas de estudio semanal
- tasa de asistencia
- nivel de desarrollo del entorno
- ubicación urbana/rural
- nivel de ingreso familiar

La selección de estas variables permite que el modelo no solo genere una predicción, sino que también ayude a comprender qué factores están asociados con un mayor o menor riesgo.

12.3 Interpretación de factores asociados al riesgo de deserción

Los resultados obtenidos mediante Odds Ratio permitieron identificar factores que incrementan o reducen la probabilidad estimada de deserción.

Entre los factores asociados a mayor riesgo destacan:

- Nivel de ingreso familiar bajo
El Odds Ratio obtenido para la categoría de ingreso familiar bajo fue de 1.48.
Esto indica que las chances de deserción aumentan aproximadamente en un 48.13% para los estudiantes pertenecientes a hogares de ingresos bajos respecto al grupo de referencia, manteniendo constantes las demás variables del modelo.
- Nivel de ingreso familiar medio
El Odds Ratio obtenido fue de 1.51.
Esto significa que las chances de deserción aumentan aproximadamente en un 50.85% para los estudiantes con ingresos familiares medios respecto al grupo de referencia, manteniendo constantes las demás variables.
- Contextos con menor desarrollo
El Odds Ratio asociado a contextos menos desarrollados fue de 1.26.
Esto indica que las chances de deserción aumentan aproximadamente en un 25.78% cuando el estudiante pertenece a un entorno con menor nivel de desarrollo, manteniendo constantes las demás variables.
Este resultado sugiere que las condiciones estructurales y el acceso a recursos pueden influir en la permanencia académica.
- Horas de acceso a internet

El Odds Ratio obtenido fue de 1.096.

Esto significa que por cada hora adicional de acceso a internet, las chances de deserción aumentan aproximadamente en un 9.63%, manteniendo constantes las demás variables.

Este comportamiento podría estar relacionado con patrones de uso digital que afectan la gestión del tiempo académico.

- Nivel de distracción digital - Brain Rot Level

El Odds Ratio fue de 1.015.

Esto indica que por cada incremento de una unidad en el nivel de distracción digital, las chances de deserción aumentan aproximadamente en un 1.54%, manteniendo constantes las demás variables.

Aunque el efecto individual es reducido, incrementos acumulados podrían generar un impacto más significativo.

- Motivación académica

El Odds Ratio fue de 0.478.

Dado que el valor es menor que 1, las chances de deserción disminuyen.

Por cada unidad adicional de motivación académica, las chances de deserción disminuyen aproximadamente en un 52.23%, manteniendo constantes las demás variables.

- Horas de contenido educativo

El Odds Ratio fue de 0.137.

Esto indica que por cada hora adicional dedicada a contenido educativo, las chances de deserción disminuyen aproximadamente en un 86.29%, manteniendo constantes las demás variables.

Este es uno de los factores protectores más importantes identificados por el modelo.

- Capacidad de atención

El Odds Ratio fue de 0.981.

Esto significa que por cada minuto adicional en la capacidad de atención, las chances de deserción disminuyen aproximadamente en un 1.87%, manteniendo constantes las demás variables.

- Horas de estudio por semana

El Odds Ratio fue de 0.965.

Esto indica que por cada hora adicional de estudio semanal, las chances de deserción disminuyen aproximadamente en un 3.53%, manteniendo constantes las demás variables.

- Tasa de asistencia

El Odds Ratio fue de 0.997.

Esto significa que por cada punto porcentual adicional en la asistencia, las chances de deserción disminuyen aproximadamente en un 0.31%, manteniendo constantes las demás variables.

Aunque el efecto unitario es pequeño, incrementos sostenidos en la asistencia pueden generar reducciones importantes en el riesgo acumulado.

- Infraestructura de internet

El Odds Ratio fue de 0.996.

Esto indica que por cada unidad adicional en el índice de infraestructura de internet, las chances de deserción disminuyen aproximadamente en un 0.36%, manteniendo constantes las demás variables.

- Edad
El Odds Ratio fue de 0.966.
Esto significa que por cada año adicional de edad, las chances de deserción disminuyen aproximadamente en un 3.45%, manteniendo constantes las demás variables.

12.4 Evaluación del desempeño del modelo

El modelo fue evaluado utilizando un conjunto de prueba equivalente al 20% de los datos. Los resultados obtenidos fueron:

Métrica	Resultado
Accuracy	79.28 %
ROC-AUC	88.33%
Recall de deserción	81%

El valor de ROC-AUC indica que el modelo posee una buena capacidad para diferenciar estudiantes con riesgo de deserción frente a aquellos que continuarán sus estudios. Además, el recall obtenido para la clase desertora muestra que el modelo logra identificar una alta proporción de estudiantes que efectivamente abandonaron sus estudios, característica relevante para un sistema de alerta temprana.

12.5 Uso del modelo dentro de EduData Analytics

El modelo predictivo complementa los dashboards e indicadores existentes, permitiendo evolucionar desde una visión descriptiva hacia una visión anticipada.

El funcionamiento esperado es:

1. La universidad recopila información del estudiante.
2. Los datos ingresan al sistema.
3. El modelo calcula una probabilidad estimada de deserción.
4. La institución identifica estudiantes con mayor nivel de riesgo.
5. Se generan acciones preventivas de acompañamiento académico.

De esta manera, EduData Analytics no solo permite conocer qué ocurre dentro de una institución, sino también anticipar posibles escenarios y apoyar decisiones oportunas.

13. Lecciones aprendidas

Referencias

- Abu-Rasheed, H., Weber, C., & Fathi, M. (2023). *Context based learning: A survey of contextual indicators for personalized and adaptive learning recommendations. A pedagogical and technical perspective*. arXiv. <https://doi.org/10.48550/arXiv.2308.16661>
- Askarbekuly, N., & Luković, I. (2024). *Learning outcomes, assessment, and evaluation in educational recommender systems: A systematic review*. arXiv. <https://doi.org/10.48550/arXiv.2407.09500>
- Aulck, L., Velagapudi, N., Blumenstock, J., & West, J. (2016). *Predicting student dropout in higher education*. arXiv. <https://doi.org/10.48550/arXiv.1606.06364>
- Bean, J. P. (1980). Dropouts and turnover: The synthesis and test of a causal model of student attrition. *Research in Higher Education*, 12, 155–187. <https://doi.org/10.1007/BF00976194>
- Bean, J. P., & Metzner, B. S. (1985). A conceptual model of nontraditional undergraduate student attrition. *Review of Educational Research*, 55(4), 485–540. <https://doi.org/10.3102/00346543055004485>
- Behr, A., Giese, M., Tegum Kamdjou, H. D., & Theune, K. (2020). Dropping out of university: A literature review. *Review of Education*, 8(2), 614–652. <https://doi.org/10.1002/rev3.3202>
- Cabrera, A. F., Nora, A., & Castañeda, M. B. (1993). College persistence: Structural equations modeling test of an integrated model of student retention. *The Journal of Higher Education*, 64(2), 123–139. <https://doi.org/10.1080/00221546.1993.11778419>
- Nigri, A., Bilancia, M., Cafarelli, B., & Magro, S. (2025). *Modelling higher education dropouts using sparse and interpretable post-clustering logistic regression*. arXiv. <https://doi.org/10.48550/arXiv.2505.07582>
- Pascarella, E. T., & Terenzini, P. T. (1980). Predicting freshman persistence and voluntary dropout decisions from a theoretical model. *The Journal of Higher Education*, 51(1), 60–75. <https://doi.org/10.1080/00221546.1980.11780030>
- Spady, W. G. (1970). Dropouts from higher education: An interdisciplinary review and synthesis. *Interchange*, 1, 64–85. <https://doi.org/10.1007/BF02214313>
- Tinto, V. (1975). Dropout from higher education: A theoretical synthesis of recent research. *Review of Educational Research*, 45(1), 89–125. <https://doi.org/10.3102/00346543045001089>

MER 5 ACLARACIONES

